

1. Uniform convergence and Model Selection

(a)由Hoeffding不等式, 我们可得对每个 \hat{h}_i ,

$$\begin{aligned} P(|\epsilon(\hat{h}_i) - \hat{\epsilon}_{S_{cv}}(\hat{h}_i)| > \gamma) &\leq 2ke^{-2\gamma^2 \beta m} \\ P(|\epsilon(\hat{h}_i) - \hat{\epsilon}_{S_{cv}}(\hat{h}_i)| \leq \gamma) &\geq 1 - 2ke^{-2\gamma^2 \beta m} \end{aligned}$$

令

$$2ke^{-2\gamma^2 \beta m} = \frac{\delta}{2}$$

可得

$$\begin{aligned} e^{2\gamma^2 \beta m} &= \frac{4k}{\delta} \\ 2\gamma^2 \beta m &= \log \frac{4k}{\delta} \\ \gamma &= \sqrt{\frac{1}{2\beta m} \log \frac{4k}{\delta}} \end{aligned}$$

因此至少有 $1 - \frac{\delta}{2}$ 的概率, 对每个 \hat{h}_i , 我们有

$$|\epsilon(\hat{h}_i) - \hat{\epsilon}_{S_{cv}}(\hat{h}_i)| \leq \sqrt{\frac{1}{2\beta m} \log \frac{4k}{\delta}}$$

(b)由(a)可得, $\forall i$

$$\epsilon(\hat{h}_i) \leq \hat{\epsilon}_{S_{cv}}(\hat{h}_i) + \sqrt{\frac{1}{2\beta m} \log \frac{4k}{\delta}} \quad (1)$$

$$\hat{\epsilon}_{S_{cv}}(\hat{h}_i) \leq \epsilon(\hat{h}_i) + \sqrt{\frac{1}{2\beta m} \log \frac{4k}{\delta}} \quad (2)$$

由不等式(2)可得, $\forall i$

$$\begin{aligned} \hat{\epsilon}_{S_{cv}}(\hat{h}) &= \min_{h \in \{\hat{h}_1, \dots, \hat{h}_k\}} \hat{\epsilon}_{S_{cv}}(h) \\ &\leq \hat{\epsilon}_{S_{cv}}(\hat{h}_i) \\ &\leq \epsilon(\hat{h}_i) + \sqrt{\frac{1}{2\beta m} \log \frac{4k}{\delta}} \end{aligned} \quad (3)$$

所以, $\forall i$

$$\begin{aligned}
\epsilon(\hat{h}) &\leq \hat{\epsilon}_{S_{\text{scv}}}(\hat{h}) + \sqrt{\frac{1}{2\beta m} \log \frac{4k}{\delta}} \\
&\leq \epsilon(\hat{h}_i) + \sqrt{\frac{1}{2\beta m} \log \frac{4k}{\delta}} + \sqrt{\frac{1}{2\beta m} \log \frac{4k}{\delta}} \\
&\leq \epsilon(\hat{h}_i) + \sqrt{\frac{2}{\beta m} \log \frac{4k}{\delta}}
\end{aligned}$$

因此

$$\epsilon(\hat{h}) \leq \min_{i=1,\dots,k} \epsilon(\hat{h}_i) + \sqrt{\frac{2}{\beta m} \log \frac{4k}{\delta}}$$

(c)由(b)可知,

$$\epsilon(\hat{h}) \leq \epsilon(\hat{h}_j) + \sqrt{\frac{2}{\beta m} \log \frac{4k}{\delta}}$$

记上述事件为 A , 记如下事件为 B

$$|\epsilon(\hat{h}_j) - \hat{\epsilon}_{S_{\text{train}}}(h_j^*)| \leq \sqrt{\frac{2}{(1-\beta)m} \log \frac{4|\mathcal{H}_j|}{\delta}}, \forall j \in \mathcal{H}_j$$

因为

$$P(A) \geq 1 - \frac{\delta}{2}, P(B) \geq 1 - \frac{\delta}{2}$$

所以

$$\begin{aligned}
P(AB) &= P(A) + P(B) - P(A \cup B) \\
&\geq 1 - \frac{\delta}{2} + 1 - \frac{\delta}{2} - 1 \\
&= 1 - \delta
\end{aligned}$$

注意 AB 即为如下事件

$$\begin{aligned}
\epsilon(\hat{h}) &\leq \epsilon(\hat{h}_j) + \sqrt{\frac{2}{\beta m} \log \frac{4k}{\delta}} \leq \left(\hat{\epsilon}_{S_{\text{train}}}(h_j^*) + \sqrt{\frac{2}{(1-\beta)m} \log \frac{4|\mathcal{H}_j|}{\delta}} \right) + \sqrt{\frac{2}{\beta m} \log \frac{4k}{\delta}}, \forall j \in \mathcal{H}_j \\
\epsilon(\hat{h}) &\leq \min_{j=1,\dots,k} \left(\hat{\epsilon}_{S_{\text{train}}}(h_j^*) + \sqrt{\frac{2}{(1-\beta)m} \log \frac{4|\mathcal{H}_j|}{\delta}} \right) + \sqrt{\frac{2}{\beta m} \log \frac{4k}{\delta}}
\end{aligned}$$

因此

$$\epsilon(\hat{h}) \leq \min_{i=1, \dots, k} \left(\hat{\epsilon}_{S_{\text{train}}}(h_j^*) + \sqrt{\frac{2}{(1-\beta)m} \log \frac{4|\mathcal{H}_j|}{\delta}} \right) + \sqrt{\frac{2}{\beta m} \log \frac{4k}{\delta}}$$

发生的概率大于等于 $1 - \delta$

2. VC Dimension

后面都用 d 表示 VC 维。

$h(x) = 1\{a < x\}$ 的 VC 维是 1，首先存在 1 个点可以 shatter，其次对于任意两个点 $x_1 < x_2$ ，标签 $(1, 0)$ 无法表出，所以

$$d = 1$$

$h(x) = 1\{a < x < b\}$ 的 VC 维是 2，首先存在 2 个点可以 shatter（作图即可），其次对于任意三个点 $x_1 < x_2 < x_3$ ，标签 $(1, 0, 1)$ 无法表出，所以

$$d = 2$$

$h(x) = 1\{a \sin x > 0\}$ 的 VC 维是 1，首先存在 1 个点可以 shatter（作图即可），其次对于任意两个点 $x_1 < x_2$ ，我们有

$$(a \sin x_1)(a \sin x_2) = \sin x_1 \sin x_2$$

所以如果

$$\sin x_1 \sin x_2 > 0$$

那么 $(1, 0)$, $(0, 1)$ 的标签无法表出。如果

$$\sin x_1 \sin x_2 \leq 0$$

那么 $(1, 1)$ 的标签无法表出。所以

$$d = 1$$

$h(x) = 1\{\sin(x + a) > 0\}$ 的 VC 维是 2，首先 $0, \frac{\pi}{2}$ 可以被 shatter，其次由于 \sin 函数的周期为 2π ，我们可以假设所有的点属于 $[0, 2\pi)$ 。在继续讨论之前，首先将模型转换，将 $[0, 2\pi)$ 上的点映射到单位圆周上， a 对应过原点的一条直线，直线一侧的点为 1，另一侧为 0。

现在假设存在三个点 $0 \leq x_1 < x_2 < x_3 < 2\pi$ 可以被 shatter，那么标签 $(1, 1, 1)$ 表出，由之前讨论可知这表示 x_1, x_2, x_3 在直线的同侧，那么可以发现 $(1, 0, 1)$ 必然无法表出，这是因为 x_1, x_3 在直线的同侧，介于两点之间的点 x_2 必然属于同侧，所以无法表出 $(1, 0, 1)$

3. ℓ_1 regularization for least squares

(a) 首先对 $J(\theta)$ 进行化简：

$$\begin{aligned}
J(\theta) &= \frac{1}{2}(X\bar{\theta} + X_i\theta_i - \vec{y})^T(X\bar{\theta} + X_i\theta_i - \vec{y}) + \lambda\|\bar{\theta}\|_1 + \lambda s_i\theta_i \\
&= \frac{1}{2}(X\bar{\theta} - \vec{y})^T(X\bar{\theta} - \vec{y}) + \frac{1}{2}\theta_i^T X_i^T X_i \theta_i + (X\bar{\theta} - \vec{y})^T X_i \theta_i + \lambda\|\bar{\theta}\|_1 + \lambda s_i\theta_i \\
&= \frac{1}{2}(X\bar{\theta} - \vec{y})^T(X\bar{\theta} - \vec{y}) + \frac{1}{2}X_i^T X_i \theta_i^2 + (X\bar{\theta} - \vec{y})^T X_i \theta_i + \lambda\|\bar{\theta}\|_1 + \lambda s_i\theta_i
\end{aligned}$$

所以

$$\frac{\partial J(\theta)}{\partial \theta_i} = X_i^T X_i \theta_i + (X\bar{\theta} - \vec{y})^T X_i + \lambda s_i$$

令上式为0可得

$$\theta_i = -\frac{(X\bar{\theta} - \vec{y})^T X_i + \lambda s_i}{X_i^T X_i}$$

如果 $s_i = 1$, 那么 $\theta_i \geq 0$, 所以我们有

$$\theta_i = \max\left\{-\frac{(X\bar{\theta} - \vec{y})^T X_i + \lambda}{X_i^T X_i}, 0\right\}$$

如果 $s_i = -1$, 那么 $\theta_i < 0$, 所以我们有

$$\theta_i = \min\left\{-\frac{(X\bar{\theta} - \vec{y})^T X_i - \lambda}{X_i^T X_i}, 0\right\}$$

(b)代码实现的过程中要分别对 $s_i = \pm 1$ 讨论, 根据选择产生较小 $J(\theta)$ 对应的 θ_i 。

```

# -*- coding: utf-8 -*-
"""
Created on Sat Mar  9 14:27:42 2019

@author: qinzen
"""

import numpy as np

X = np.genfromtxt("x.dat")
y = np.genfromtxt("y.dat")
theta_true = np.genfromtxt("theta.dat")

def l1l2(X, y, Lambda):
    #数据维度
    n, d = X.shape
    #设置阈值
    D = 1e-5
    #设置初始值
    theta = np.zeros(d)
    #记录上一轮迭代的theta
    theta_pre = np.copy(theta)
    while True:

```


0.	0.	0.	0.	0.	0.
0.	0.	0.	0.	0.	0.
0.	0.	0.	0.	0.	0.
0.	0.	0.	0.]	

可以看到最终的 θ 是稀疏的，所以可以用 l_1 正则化进行特征选择，保留系数不为0的特征。

4. K-Means Clustering

这里使用向量化的方法计算每个点距离聚类中心的距离，提高计算效率，介绍如下

假设

$$X = \begin{bmatrix} -(x^{(1)})^T \\ -(x^{(2)})^T \\ \vdots \\ -(x^{(m)})^T \end{bmatrix} \in \mathbb{R}^{m \times d}, Y = \begin{bmatrix} -(y^{(1)})^T \\ -(y^{(2)})^T \\ \vdots \\ -(y^{(n)})^T \end{bmatrix} \in \mathbb{R}^{n \times d}$$

其中 $x^{(i)}, y^{(j)} \in \mathbb{R}^d$ ，现在的问题是如何高效计算矩阵 $D \in \mathbb{R}^{m \times n}$ ，其中

$$D_{i,j} = \|x^{(i)} - y^{(j)}\|^2$$

首先对 $D_{i,j}$ 进行处理

$$\begin{aligned} D_{i,j} &= \|x^{(i)} - y^{(j)}\|^2 \\ &= (x^{(i)} - y^{(j)})^T (x^{(i)} - y^{(j)}) \\ &= (x^{(i)})^T x^{(i)} - 2(x^{(i)})^T y^{(j)} + (y^{(j)})^T y^{(j)} \end{aligned}$$

那么

$$\begin{aligned} D &= \begin{bmatrix} D_{1,1} & \dots & D_{1,n} \\ \dots & \dots & \dots \\ D_{m,1} & \dots & D_{m,n} \end{bmatrix} \\ &= \begin{bmatrix} (x^{(1)})^T x^{(1)} - 2(x^{(1)})^T y^{(1)} + (y^{(1)})^T y^{(1)} & \dots & (x^{(1)})^T x^{(1)} - 2(x^{(1)})^T y^{(n)} + (y^{(n)})^T y^{(n)} \\ \dots & \dots & \dots \\ (x^{(m)})^T x^{(m)} - 2(x^{(m)})^T y^{(1)} + (y^{(1)})^T y^{(1)} & \dots & (x^{(m)})^T x^{(m)} - 2(x^{(m)})^T y^{(n)} + (y^{(n)})^T y^{(n)} \end{bmatrix} \\ &= \begin{bmatrix} (x^{(1)})^T x^{(1)} & \dots & (x^{(1)})^T x^{(1)} \\ \dots & \dots & \dots \\ (x^{(m)})^T x^{(m)} & \dots & (x^{(m)})^T x^{(m)} \end{bmatrix} + \begin{bmatrix} (y^{(1)})^T y^{(1)} & \dots & (y^{(n)})^T y^{(n)} \\ \dots & \dots & \dots \\ (y^{(1)})^T y^{(1)} & \dots & (y^{(n)})^T y^{(n)} \end{bmatrix} - 2 \begin{bmatrix} (x^{(1)})^T y^{(1)} & \dots & (x^{(1)})^T y^{(n)} \\ \dots & \dots & \dots \\ (x^{(m)})^T y^{(1)} & \dots & (x^{(m)})^T y^{(n)} \end{bmatrix} \\ &= \begin{bmatrix} (x^{(1)})^T x^{(1)} \\ \dots \\ (x^{(m)})^T x^{(m)} \end{bmatrix} \underbrace{\begin{bmatrix} 1 & \dots & 1 \end{bmatrix}}_{1 \times n \text{ 矩阵}} + \underbrace{\begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}}_{m \times 1 \text{ 矩阵}} \begin{bmatrix} (y^{(1)})^T y^{(1)} & \dots & (y^{(n)})^T y^{(n)} \end{bmatrix} - 2XY^T \end{aligned}$$

利用numpy的广播机制上式可以简写如下：

```

#计算距离矩阵
d1 = np.sum(X ** 2, axis=1).reshape(-1, 1)
d2 = np.sum(centroids ** 2, axis=1).reshape(1, -1)

dist = d1 + d2 - 2 * X.dot(centroids.T)

```

全部代码如下：

```

# -*- coding: utf-8 -*-
"""
Created on Sat Mar  9 15:41:53 2019

@author: qinzhen
"""

import numpy as np
import matplotlib.pyplot as plt

def draw_clusters(X, clusters, centroids):
    #颜色列表
    c = ["b", "g", "r", "c", "m", "y"]
    #聚类数量
    d = np.max(clusters)
    #画出每种聚类
    for i in range(d+1):
        plt.scatter(X[clusters==i][:, 0], X[clusters==i][:, 1], c=c[i], s=1)

    #画出中心
    plt.scatter(centroids[:, 0], centroids[:, 1], c="black")
    plt.show()

def k_means(X, k, plot=0):
    #数据维度
    n, d = X.shape
    #聚类标签
    clusters = np.zeros(n, dtype=int)
    #初始中心点
    index = np.random.randint(0, n, k)
    #centroids = np.random.rand(k, d)
    centroids = X[index]
    #记录上一轮迭代的聚类中心
    centroids_pre = np.copy(centroids)
    #设置阈值
    D = 1e-5

    while True:
        #计算距离矩阵
        d1 = np.sum(X ** 2, axis=1).reshape(-1, 1)
        d2 = np.sum(centroids ** 2, axis=1).reshape(1, -1)
        dist = d1 + d2 - 2 * X.dot(centroids.T)

        #STEP1:找到最近的中心

```

```

clusters = np.argmin(dist, axis=1)
#STEP2:重新计算中心
for i in range(k):
    centroids[i] = np.mean(X[clusters==i], axis=0)

#计算误差
delta = np.linalg.norm(centroids - centroids_pre)

#判断是否作图
if plot:
    draw_clusters(X, clusters, centroids)



if delta < D:
    break


centroids_pre = np.copy(centroids)

X = np.genfromtxt("X.dat")

k_means(X, 3, plot=1)

```





5. The Generalized EM algorithm

(a)

$$\begin{aligned}
 l(\theta^{(t+1)}) &\geq \sum_i \sum_{z^{(i)}} Q_i^{(t)}(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \theta^{(t+1)})}{Q_i^{(t)}(z^{(i)})} \\
 &\geq \sum_i \sum_{z^{(i)}} Q_i^{(t)}(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \theta^{(t)})}{Q_i^{(t)}(z^{(i)})} \\
 &= l(\theta^{(t)})
 \end{aligned}$$

第一个不等号成立是因为如下不等式对任意 Q_i 和 θ 都成立

$$l(\theta) \geq \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})}$$

第二个不等号成立是因为梯度上升，等号成立是由 $\theta^{(t)}$ 的定义。

(b)利用定义求梯度即可

$$\begin{aligned}\nabla_{\theta} \sum_i \log \sum_{z^{(i)}} p(x^{(i)}, z^{(i)}; \theta) &= \sum_i \frac{\nabla_{\theta} \sum_{z^{(i)}} p(x^{(i)}, z^{(i)}; \theta)}{\sum_{z^{(i)}} p(x^{(i)}, z^{(i)}; \theta)} \\ &= \sum_i \sum_{z^{(i)}} \frac{\nabla_{\theta} p(x^{(i)}, z^{(i)}; \theta)}{p(x^{(i)}; \theta)}\end{aligned}$$

注意到GEM中的梯度为

$$\begin{aligned}\nabla_{\theta} \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})} &= \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \nabla_{\theta} \log p(x^{(i)}, z^{(i)}; \theta) \\ &= \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \frac{\nabla_{\theta} p(x^{(i)}, z^{(i)}; \theta)}{p(x^{(i)}, z^{(i)}; \theta)}\end{aligned}$$

注意我们选择

$$Q_i(z^{(i)}) = p(z^{(i)} | x^{(i)}; \theta) = \frac{p(x^{(i)}, z^{(i)}; \theta)}{p(x^{(i)}; \theta)}$$

所以GEM中的梯度为

$$\begin{aligned}\nabla_{\theta} \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})} &= \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \frac{\nabla_{\theta} p(x^{(i)}, z^{(i)}; \theta)}{p(x^{(i)}, z^{(i)}; \theta)} \\ &= \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \frac{\nabla_{\theta} p(x^{(i)}, z^{(i)}; \theta)}{p(x^{(i)}; \theta) Q_i(z^{(i)})} \\ &= \sum_i \sum_{z^{(i)}} \frac{\nabla_{\theta} p(x^{(i)}, z^{(i)}; \theta)}{p(x^{(i)}; \theta)}\end{aligned}$$

所以这两者等价。